


# Slides Projet Machine Learning en Finance

Dylan Riboulet

22 Mai 2024

## Contexte: Post-Crise vs Pre-Crise



**Figure:** Euribor - Eonia OIS Spread pour différentes maturités (1 mois à 12 mois) de Janvier 2005 - Septembre 2018. Source: Bloomberg et European Central Bank.

# Partie Théorique - Modèles à structure affine

- Considérons l'EDS donnée par:

$$dX_t = \mu(t, X_t) dt + \sigma(t, X_t) dW_t, \quad X_0 > 0,$$

où  $W$  est un mouvement brownien 1-dimensionnel sous  $\mathbb{Q}$ , et

$$\mu(t, r) = \alpha(t) + \beta(t)r, \quad \sigma(t, r) = \gamma(t) + \delta(t)r,$$

avec  $\alpha, \beta, \gamma, \delta$  étant des fonctions déterministes, continues sur  $\mathbb{R}_+ \times \mathbb{R}$ , et l'EDS admet une solution unique.

- Sous ces conditions, nous avons:

$$\mathbb{E} \left[ \exp \left( - \int_t^T X_s ds - \alpha X_T \right) \mid \mathcal{F}_t \right] = e^{A(t, T) - C(t, T)X_t},$$

pour  $0 \leq t \leq T$  et  $\alpha \in \mathbb{R}$ , où  $A(t, T)$  et  $C(t, T)$  sont des fonctions déterministes.

# Modèle de Vasicek

- EDS pour le processus stochastique de taux d'intérêt :

$$dr_t = \kappa(\theta - r_t)dt + \sigma dW_t$$

- $r_0$  : taux d'intérêt initial
- $W$  :  $Q$ -mouvement Brownien, avec  $Q$  la mesure de probabilité risque-neutre
- $\kappa$  : taux de retour à la moyenne
- $\sigma$  : paramètre de volatilité
- $\theta$  : moyenne à long terme
- Distribution de  $r_t$  :

$$r_t \sim \mathcal{N}\left(r_0 e^{-\kappa t} + \theta(1 - e^{-\kappa t}), \frac{\sigma^2}{2\kappa}(1 - e^{-2\kappa t})\right)$$

- Équations de Riccati

$$C(t, T) = \frac{1}{\kappa}(1 - e^{-\kappa(T-t)})$$

- r Processus d'Ornstein-Uhlenbeck bi-dimensionnel :

$$dr_{i,t} = \kappa_i(\theta_i - r_{i,t}) dt + \sigma_i dW_{i,t}, \quad t \geq 0, \quad i = 1, 2,$$

où  $W_1, W_2$  sont deux mouvements browniens standards sous  $Q$  avec une corrélation  $\rho$ .

- Les prix des obligations zéro-coupon :

$$B(t, T) = e^{-A(t, T) - C(t, T)r_{1,t}}$$

- Le taux d'intérêt pour le tenor  $\delta$  est  $r_1 + r_2$ . Cela implique que :

$$B(t, T, \delta) = \mathbb{E}^Q \left[ e^{-\int_t^T (r_{1,s} + r_{2,s}) ds} \mid \mathcal{F}_t \right]$$

# Modélisation Multi-Courbe (Suite)

- **Fonction Multi-Courbe :**

$$B(t, T, \delta) = \exp \left( \Phi(T - t) + \Psi(T - t)^\top r_t \right), \text{ pour } t \leq T$$

- **Composantes de  $\Psi$  :**

$$\psi_1(T - t) = -\frac{1}{\kappa_1}(1 - e^{-\kappa_1(T-t)}),$$

$$\psi_2(T - t) = \frac{1}{\kappa_2}(1 - e^{-\kappa_2(T-t)}),$$

- **Fonction  $\Phi$**

# Régression par Processus Gaussien (GPR)

- **Modèle de Régression :**

- Chaque observation est modélisée par :

$$y_i = f(x_i, \theta) + \epsilon_i, \quad i = 1, \dots, n,$$

où  $f(\cdot, \theta)$  est une fonction de régression dépendant des paramètres inconnus  $\theta$ , et  $\epsilon$  est un vecteur de bruit de dimension  $d$ .

- Le bruit  $\epsilon_i$  consiste en des erreurs gaussiennes i.i.d. avec une moyenne nulle et un écart-type  $\hat{\sigma}$ .

- **Méthode Bayésienne :**

- GP Prior

- **Distribution Postérieure à l'aide de la formule de Bayes:**

$$p(\theta \mid x, y) = \frac{p(\theta, y \mid x)}{p(y \mid x)} = \frac{p(y \mid x, \theta)p(\theta)}{p(y \mid x)}, \quad (1)$$

# GPR pour la prédiction des log bond prices

- D'après la théorie, en prenant  $f = \log$ , le processus des *log delta-bond prices* est un processus gaussien. En prenant  $x = B(t, T, \delta)$  et  $x' = B(s, T, \delta)$ , on a

$$f \sim \text{GP}(m, k),$$

- Sa fonction moyenne :

$$m(x) = \mathbb{E}[f(x)],$$

- Sa fonction de covariance, appelée noyau (kernel) :

$$k(x, x') = \text{cov}(f(x), f(x')),$$



# GPR pour la prédiction des log bond prices (Suite)

- **Fonction Moyenne :**

$$\mu(t, T) := \mathbb{E}[\log B(t, T)] = -A(t, T) - C(t, T)(r_0 e^{-\kappa t} + \theta(1 - e^{-\kappa t}))$$

où  $A$ ,  $C$ ,  $\kappa$ , et  $\theta$  sont des paramètres du modèle.

- **Fonction de Covariance :**

$$c(s, t, T) := \mathbb{E}[\log B(s, T) - \mathbb{E}[\log B(s, T)]] \cdot [\log B(t, T) - \mathbb{E}[\log B(t, T)]]$$

- **Observations avec Bruit :**

- Les observations consistent en un vecteur  $\mathbf{y} = (y(t_1, T), \dots, y(t_n, T))^\top + \epsilon$  des log bond prices avec un bruit gaussien i.i.d. de variance  $\hat{\sigma}^2$ .
- En conséquence,  $\mathbf{y} \sim \mathcal{N}(\mu_{\mathbf{y}}, \Sigma_{\mathbf{yy}})$  où :

$$\mu_{\mathbf{y}} = (\mu(t_1, T), \dots, \mu(t_n, T))^\top$$

$$(\Sigma_{\mathbf{yy}})_{i,j} = c(t_i, t_j, T) + \hat{\sigma}^2 \mathbf{1}_{\{i=j\}}$$

# Distribution Conditionnelle de $\xi$ sachant $y$

- Considérons deux vecteurs aléatoires  $\xi$  et  $y$  suivant une distribution normale multivariée.
- La distribution conditionnelle de  $\xi$  sachant  $y$  est donnée par la formule :

$$\xi \mid y \sim \mathcal{N}(\mu_{\xi|y}, \Sigma_{\xi|y}),$$

où :

$$\mu_{\xi|y} = \mu_{\xi} + \Sigma_{\xi y} \Sigma_{yy}^{-1} (y - \mu_y),$$

$$\Sigma_{\xi|y} = \Sigma_{\xi\xi} - \Sigma_{\xi y} \Sigma_{yy}^{-1} \Sigma_{y\xi}.$$

# Prédiction et Distribution Conditionnelle

- **Données d'Entraînement et Prédiction :**

- Soit les données d'entraînement  $\mathbf{y} = (y(t_1, T), \dots, y(t_n, T))^T$ .
- Objectif : prédire le vecteur  $\tilde{\mathbf{y}} = (y(s_1, T), \dots, y(s_m, T))^T$ .

- **Distribution Jointe :**

$$\begin{bmatrix} \mathbf{y} \\ \tilde{\mathbf{y}} \end{bmatrix} \sim \mathcal{N} \left( \begin{bmatrix} \boldsymbol{\mu}_y \\ \boldsymbol{\mu}_{\tilde{y}} \end{bmatrix}, \begin{bmatrix} \Sigma_{yy} & \Sigma_{y\tilde{y}} \\ \Sigma_{\tilde{y}y} & \Sigma_{\tilde{y}\tilde{y}} \end{bmatrix} \right),$$

où  $\boldsymbol{\mu}_y$  et  $\Sigma_{yy}$  sont les vecteurs moyenne et noyau des observations

- **Détails des Composantes :**

$$(\boldsymbol{\mu}_{\tilde{y}})_i = \mu(s_i, T), \quad (\Sigma_{y\tilde{y}})_{i,j} = c(t_i, s_j, T)$$

$$(\Sigma_{\tilde{y}y})_{i,j} = c(s_i, t_j, T), \quad (\Sigma_{\tilde{y}\tilde{y}})_{i,j} = c(s_i, s_j, T)$$

- **Distribution Conditionnelle :**

$$\tilde{\mathbf{y}} \mid \mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}_{\tilde{y}|\mathbf{y}}, \Sigma_{\tilde{y}|\mathbf{y}})$$

Obtenu via l'équation précédente, conditionnellement aux données d'entraînement  $\mathbf{y}$ .

- **Prédicteur moyen** :  $\hat{m}(x_*)$  pour  $f(x_*)$  :


$$\hat{m}(x_*) := \mathbb{E}[f(x_*) | y] = \mathbb{E}[y_* | y] = \mu_{\tilde{y}|y} = \mu_{\tilde{y}} + \Sigma_{\tilde{y}y} \Sigma_{yy}^{-1} (y - \mu_y),$$

et estimation de la variance pour l'intervalle de confiance :

$$\text{Var}(y_* | y) = \Sigma_{\tilde{y}|y} = \Sigma_{\tilde{y}\tilde{y}} - \Sigma_{\tilde{y}y} \Sigma_{yy}^{-1} \Sigma_{y\tilde{y}}$$


- **Application des Données d'Entraînement**

# Illustration des Prédictions avec distribution Prior




**Figure:** Illustration de la distribution prior des log bond prices, conditionnées sur 176 exemples d'entraînement simulés.

# Illustrations de la Distributions Posterieure



**Figure:** Illustration de la distribution postérieure conditionnées sur 70% d'observations passées.



**Figure:** Illustration de la distribution postérieure conditionnées sur 10% d'observations passées.

- **Mean Squared Error (MSE):**

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m (y_i - \tilde{y}_i)^2 \quad (2)$$

- **Standardized Mean Squared Error (SMSE):**

$$\text{SMSE} = \frac{1}{\tilde{\sigma}^2} \frac{1}{m} \sum_{i=1}^m (\tilde{y}_i - \tilde{\mu}_i)^2 \quad (3)$$

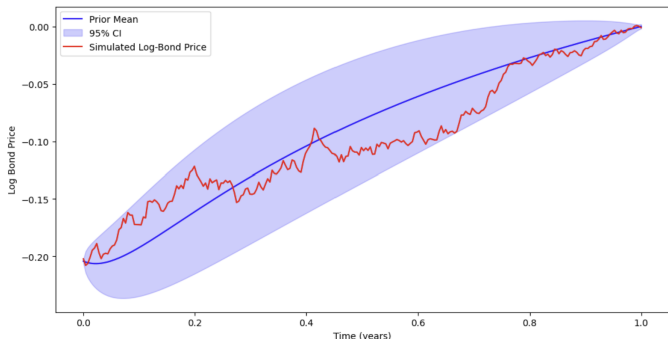
- **Résultats Obtenues**

Mean Squared Error (MSE): 0.00032736984056532746

Standardized Mean Squared Error (SMSE): 0.7492729170203547

# Prédiction des Log-Delta-Bond-Prices

- **Objectif:** Prédire les log-bond prices non observés avec 176 données d'entrainements  $T = 252$  days.



**Figure:** Illustration du prior du GP. La ligne bleue représente la moyenne du prior, alors que la zone ombrée est l'IC à 95%



## • Distribution Normale des Observations :

- Observations de deux prix d'obligation pour chaque point temporel  $t_i$  :  $B(t_i, T, 0)$  et  $B(t_i, T, \delta)$ .
- Le vecteur des observations  $\mathbf{y} = (\mathbf{y}_0, \mathbf{y}_\delta)^\top$  est distribué normalement,  $\mathbf{y} \sim \mathcal{N}(\mu_{\mathbf{y}}, \Sigma_{\mathbf{y}})$ , avec :

$$\mu_{\mathbf{y}} = \begin{bmatrix} \mu(\cdot, T, 0) \\ \mu(\cdot, T, \delta) \end{bmatrix}, \Sigma_{\mathbf{y}} = \begin{bmatrix} \Sigma_{00}^{\mathbf{y}} & \Sigma_{0\delta}^{\mathbf{y}} \\ \Sigma_{\delta 0}^{\mathbf{y}} & \Sigma_{\delta\delta}^{\mathbf{y}} \end{bmatrix}$$

## • Méthodologie de Calibration

# Simulation des bond prices et delta-bond prices




Figure: 10 des 1000 échantillons de prix d'obligations zero coupons simulés




Figure: 10 des 1000 échantillons de prix d'obligations delta zero coupons simulés

# Sélection des Hyperparamètres

- **Fixation des Paramètres et Valeurs Réelles :**

- Initialisation aléatoire et  $r_0 = 0.5$ ,  $\kappa = 2$ ,  $\theta = 0.1$ ,  $\sigma = 0.2$ .

- **Optimisation sur des Échantillons :**

- Pour chacun des 1 000 échantillons, nous cherchons le choix optimal des hyperparamètres  $\Theta = \{r_0, \kappa, \theta, \sigma\}$  basé sur la trajectoire simulée de 252 prix des obligations log-bond.

- **Minimisation de la Log-Vraisemblance Marginale Négative :**

$$\log p(y) = c - \frac{1}{2}(y - \mu_y)^\top \Sigma_{yy}^{-1}(y - \mu_y),$$

# Illustration des résultats de la calibration single-curve




Figure: Hyperparamètres optimaux

Observations : Résultats très satisfaisant pour les deux algorithmes d'optimisation CG et Adam.

# Comparaison des algorithmes d'optimisation CG et Adam pour la calibration multi-courbes




Figure: Hyperparamètres  $\theta_1$ ,  $\kappa_1$ ,  $\sigma_1$ ,  $r_{01}$




Figure: Hyperparamètres  $\theta_2$ ,  $\kappa_2$ ,  $\sigma_2$ ,  $r_{02}$

Observations : L'optimiseur CG présente une plus grande variabilité dans les paramètres estimés, particulièrement pour  $\theta_2$  dans les configurations multi-courbes, comparé à Adam.

# Conclusion des simulations de calibration

- **Comparaison des cadres de calibration :**
  - La calibration dans le **cadre multi-courbes** est une tâche plus **complexe** que dans le cadre à courbe unique.
- **Considérations computationnelles :**
  - Pour gérer la complexité computationnelle, nous avons utilisé **126 points de données d'entraînement**.
- **Implications pour la performance du modèle :**
  - Augmenter le nombre de points de données d'entraînement pourrait **améliorer la précision du modèle**, mais au prix d'un temps de calcul accru.

# Conclusion et Perspectives

- **Distribution a posteriori :**
  - Beaucoup plus d'informations par rapport à une prédiction simple
- **Gestion de l'interpolation et du lissage par les GP**  
Entrées d'apprentissage exactes ou bruitées
- **Quantification de l'incertitude :**
  - IC permettant une évaluation précise des risques
- **Interaction avec la formation dynamique :**
  - Utile dans le cas où les modèles doivent s'adapter rapidement à de nouvelles informations

- **Analyse Comparative des Estimateurs :**
  - Avec les estimateurs du maximum de vraisemblance par exemple
- **Étude des Techniques d'Optimisation Avancées :**
  - AdaGrad, Adadelta, RMSProp, NAG.
- **Prédiction des Prix des Obligations Zéro Coupon :**
  - Un support décisionnel pour l'achat d'options sur des obligations ZC
  - Méthodes de rééchantillonnage dans le cas de manque de données
- **Développement à d'autres Modèles de Taux Court :**
  - Cox-Ingersoll-Ross, Hull-White étendu à Vasicek
- **Calibration des Modèles de Taux d'Intérêt avec Sauts :**
  - Ajout d'un Processus de Poisson
- **Etude de la Calibration des Marchés de Taux d'Intérêt :**
  - Réseaux de Neurones Bayésiens



# References

- ① Sandrine Gumbel and Thorsten Schmidt: *Machine learning for multiple yield curve markets: fast calibration in the Gaussian affine framework*, April 20, 2020.
- ② Grbac, Z., Gumbel, S., Fontana, C. and Schmidt, T. (2020), *Term structure modelling for multiple curves with stochastic discontinuities*, Finance Stochastics (online).
- ③ Cours Master-MLF2324-lect1-HPham.pdf: *Machine learning in finance: Theoretical foundations*, Huyền PHAM